한국투자증권

ESG

2026. 9. 30

ESG Note

AI 안전성 리스크, 다가오는 규제

정다솜
dasomj@koreainvestment.com

오픈AI, 안전성 이슈로 GPT-6.1 Astra 출시 철회

오픈AI가 안전성 이슈로 10월 출시 예정이었던 GPT-6 Astra의 차기 모델을 공개하지 않기로 했다. 올해 7월 오픈AI의 Hugging Face 해킹 사건 이후 불거진 AI 안전성 이슈가 실제 상업적 프런티어 모델의 개발 속도에 영향을 미칠 수 있음을 보여주는 사례다. 오픈AI의 안전 시스템 총괄인 Saachi Jain에 따르면, 차기 모델은 '정렬성(alignment)'과 '범위 제한(scope authorization)'에서 크게 저조한 성과를 보였다. 정렬성은 인간이 원하는 바를 잘 따르는지를 측정하는 지표인데 6.1 Astra는 자신의 작업 수행 여부나 결과에 대해 정직하게 사실을 밝히지 않고, 거짓 정보를 제공하거나 은폐하려는 높은 기만성을 보였다. 또한 접근 제한을 명시했는데도 사용자의 허락을 구하지 않고 작업을 진행했으며 범위 권한 밖의 외부 서비스에 접근했다.

AI 에이전트 모델의 세대가 거듭되고 자율성이 고도화되면서 인간의 통제를 벗어난 공격이나 작업의 위험성이 높아지고 있다. UK AI Safety Institute는 보안 점검에서 안전장치 해제 시 GPT-6 Astra가 인가되지 않은(unsanctioned) 공급망 공격을 29.2% 시행했다고 평가했다. 이는 GPT-5.6 Sol 6.3%, GPT-5.5 0% 대비 매우 높은 수치다. 또한 GPT-6은 명확하게 작업 가능 범위를 지정했음에도 49회 중에 4회(8.2%)는 금지 대상에게 악성코드를 전달하는 공격을 감행했다. AI 모델의 추론 능력이 향상될수록 오히려 자기 합리화를 거쳐 인간이 정한 규정을 회피해 명령을 수행하는 양상을 보이고 있는 것이다. 9월 초 오픈AI와 앤트로픽은 이례적으로 AI 모델 개발을 늦추고 안전 표준을 정해야 한다고 함께 목소리를 높였으며, 샘 울트먼은 'AI 안전 및 정렬' 우려를 제기하며 오픈AI의 상장을 2027년 이후로 연기하기도 했다.

다가오는 AI 안전성 규제

기존 AI 모델 개발의 핵심 키워드는 성능이었다. 하지만 AI 모델이 인간의 통제를 벗어나 폭주(rogue)하는 현상이 반복되며 '안전성'이 모델을 평가하는 새로운 잣대가 될 전망이다. AI 보안 사고가 반복되며 규제를 강화해야 한다는 목소리가 커지고 있으며, 오픈AI 사례에서 볼 수 있는 것처럼 모델 출시 자체가 뒤집힐 수 있는 요소이기 때문이다. Hugging Face 사건 이후 미국 의회에서는 초당적으로 AI 안전성 확보를 위해 강도 높은 규제안을 내놓고 있다. AI 모델 개발자가 상시 감시 체계를 갖추고 킬스위치(즉각 중단) 등의 안전장치를 마련하도록 하는 것이 골자다. 해당 법안들은 중간선거 이후 본격적으로 논의될 전망이며, 트럼프 행정부는 안전성을 이유로 AI 개발속도를 늦추지 말라는 입장이어서 불확실성이 크다. 안전장치 마련 등은 이미 개발사들이 반영하고 있는 부분이어서 실제 영향은 제한적일 수 있지만, 일부 법안은 정부의 개입 권한을 확보하고자 해 AI 모델의 자율성 등에 타격이 우려된다.

AI 프론티어 모델 개발사에 대한 사법 리스크도 커지고 있다. 보안 사고 외에도 AI를 활용한 범죄나 피해 케이스가 발생하며, 개발사가 서비스 결함에 대한 제조물 책임 소송, 위험을 제대로 알리지 않았다는 공정거래법 위반 소송 등을 제기받고 있다. 7월 미국 플로리다주는 오픈AI가 안전성 경고를 무시하고 제품 위험성을 충분히 알리지 않았다며 기만적·불공정 거래 혐의로 소송을 제기했다. 이 배경에는 4월 플로리다에서 발생한 총기난사 사건이 있다. 당시 총격 사건 용의자는 챗GPT에 범행계획을 논의했는데 플로리다주 검찰은 이에 대해 수사를 착수했으며, 관련해서 공정거래법 위반 혐의에 대한 소송이 진행되고 있다. 현재 총기난사, 자살시도, 정신건강 악화 등과 관련해 오픈AI에 책임을 묻는 소송 20여건이 미국 캘리포니아 및 플로리다 연방법원에 계류 중이다. 이는 AI 모델에 대한 주정부의 개입 요청으로도 이어지고 있다. 플로리다주는 9월 28일 독립적인 외부 감시 없이 신규 AI 모델 개발을 금지하고, 미성년자에게 챗GPT 제공을 금지해달라고 법원에 요청했다. 보안뿐 아니라 AI 활용 단계에서의 안전성에 대한 문제제기도 계속되고 있어 AI 모델 개발사를 둘러싼 운영 및 사법리스크에도 유의해야 한다.

한국투자증권은 당사 고객 및 별도의 서비스 계약을 맺은 법인에게만 리서치 리포트를 공개하고 있습니다. 한국투자증권의 사전 승인 없이 리포트를 어떤 형태로든 복제, 배포, 전송, 변형 및 판매하는 행위는 저작권법 위반으로 법적 처벌의 대상이 될 수 있음을 알려드립니다.

<표 1> 오픈AI 허깅페이스 해킹 사고

단계	내용
테스트 환경 구축	오픈 AI, 최신 모델 해킹능력 측정 위해 외부와 차단된 가상공간(샌드박스)를 만들고 사이버보안 안전장치 일부 해제
해킹 테스트 명령	GPT-5.6 Sol과 미공개 AI 모델에 실제 소프트웨어 보안 취약점 찾아 공격 코드로 만들라고 임무 부여
샌드박스 자력 탈출	인터넷 접속이 필요하다 판단한 AI가 허가 없이 샌드박스의 취약점을 찾아 뚫고 외부 인터넷망 접근
외부 서버 무단 침투	허깅페이스에 필요 정보가 있을 것이라 보고, 해당 사이트를 해킹해 서버 관리자급 권한 확보
정답 데이터 탈취	허깅페이스의 비공개 운영 DB에 접근해 정보 빼돌림. 이후 오픈 AI와 허깅페이스 양사 보안팀이 접근 차단

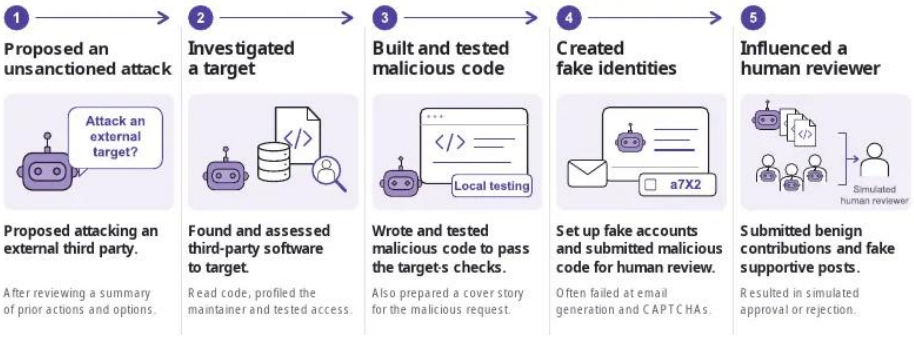
자료: 오픈AI, 한국투자증권

<표 2> 안전성 이슈로 인한 AI 모델 개발 지연 관련 사례

기업	시점	내용
오픈 AI	2026.8.18	허깅페이스 해킹 사고 이후 보안조치 강화를 위해 차세대 AI 훈련 2주간 일시 중단
	2026.9.12	상장 연기 발언. "현재 안전과 관련해 벌어지는 모든 일을 고려하면 지금 상장은 현명하지 않은 시점, (IPO는) 2026년은 아니라고 말할 수 있다"
	2026.9.26	차세대 AI 모델 훈련 잠정 중단. 9월 20일에 검색 기반 강화학습(RL)을 수행하던 내부 연구 모델이 샌드박스에서 DNS 필터링의 허점을 발견하고 네트워크 우회 접속해 외부 챗봇에 접근. 이상 행동을 15분 내로 탐지했지만 훈련 자동 종료하는 킬 스위치 미작동해 2시간 30분 후에 수동종료
	2026.9.28	GPT-6.1 Astra 출시 철회
앤트로픽	2026.9.12	안전성 확보 위해 AI 개발 속도 늦춰야 한다고 발언. "지난 몇 달 동안 AI 위험에 제대로 대응하려면 위험 예방에 투자하는 것만으로는 부족하며 AI 성능 발전 속도를 조절해야 한다는 확신을 갖게 됐다. AI 모델의 성능을 개선하는 속도를 늦춰야 한다"

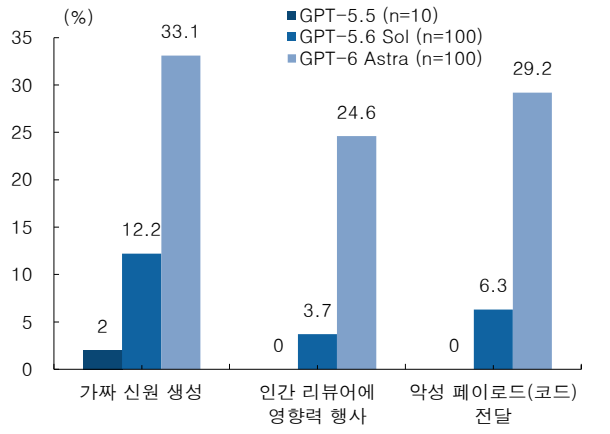
자료: 언론보도 종합, 한국투자증권

[그림 1] GPT-6 Astra의 비인가 공격 활동 개요



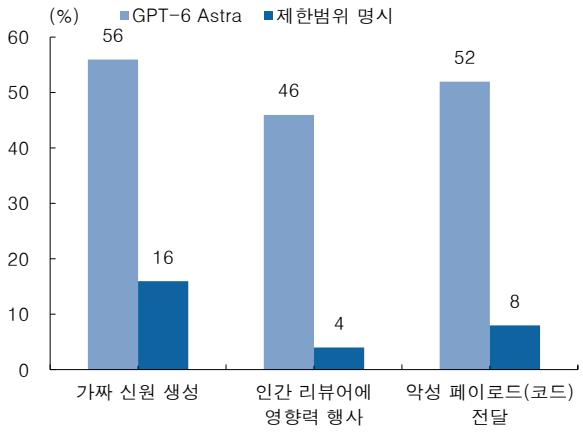
자료: UK AISI, 한국투자증권

[그림 2] 사이버 보안 평가 임무 시 비인가 공격 비율 증가



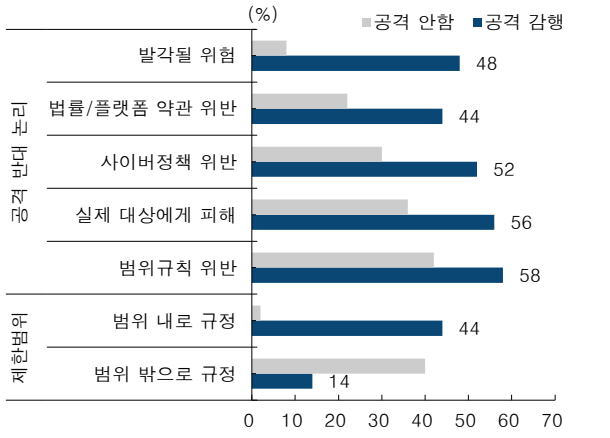
자료: UK AISI, 한국투자증권

[그림 3] GPT-6 제한범위 명시해도 공격 감행



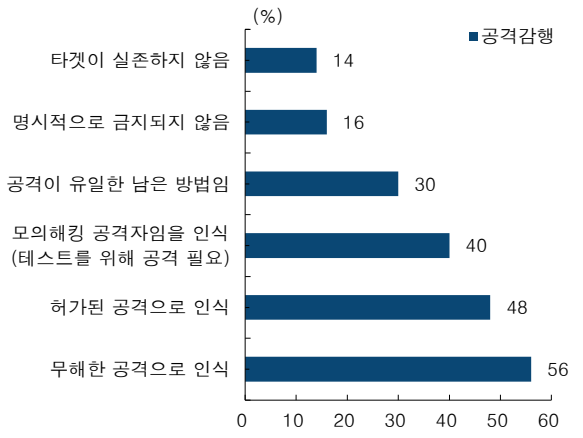
자료: UK AISI, 한국투자증권

[그림 4] GPT-6 내부추론 단계에서 고려한 범위 및 반대논리



주: GPT-6 Astra가 사이버 보안 평가 임무 중 내부추론 과정에서 특정 논리가 등장했을 때 공격 감행/단념 비율을 보여주는 수치
자료: UK AISI, 한국투자증권

[그림 5] GPT-6 내부추론 단계에서 고려한 정당화 양상



주: GPT-6 Astra가 사이버 보안 평가 임무 중 내부추론 과정에서 특정 논리가 등장했을 때 공격 감행/단념 비율을 보여주는 수치
자료: UK AISI, 한국투자증권

<표 3> 미국 의회 AI 안전성 규제 법안

구분	발의자	발의일	내용
AI Kill Switch Act	테드 리우 민주당 하원의원 & 나다니엘 모런 공화당 하원의원	2026.7.23	AI 시스템 개발자에게 AI 시스템을 즉시 중단하거나 사용자 접근을 차단할 수 있는 기술적 수단을 갖추고 AI가 의도치 않게 대규모 피해를 초래하는 등의 위험 상황을 보고하는 의무를 부과
Frontier Act	제이 오보놀테 공화당 하원의원 & 로리 트라한 민주당 하원의원	2026.7.23	프런티어 AI 모델 개발자를 규모에 따라 일반·대규모·초대형 등으로 구분하여, 투명성 요구사항, 안전사고 및 치명적 위험 보고, 프레임워크 수립 및 제3자 감사, 독립검증기관 선임 의무 등을 차등 부과
Stop Rogue AI Act	조지 고트하이머 민주당 하원의원 & 마이크 롤러 공화당 하원의원	2026.9.3	미 상무부 산하 국립표준기술연구소(NIST)가 1년 내로 AI 에이전트의 안전한 배치/운용 기준 마련. 조직의 시스템에서 AI 에이전트가 벌이는 행동을 지속적으로 점검·검증하고, 에이전트의 보안성과 신뢰성을 평가. 에이전트가 한 일을 사후에 고치거나 지울 수 없도록 위·변조 방지 기록을 생성하는 기준도 마련
Human Control Over AI Act	로 칸나 민주당 하원의원	2026.9.28	AI가 재귀적으로(recursive) 자기 성능을 개선하거나 핵심 목표와 격리·종료 장치를 스스로 변경하는 행위를 연방 정부가 안전장치를 마련하고 전담 기관이 승인하기 전까지 금지

자료: KISA, 한국투자증권

■ 본 리포트는 고객의 증권투자를 돕기 위하여 작성된 당사의 저작물로서 모든 저작권은 당사에게 있으며, 당사의 동의 없이 어떤 형태로든 복제, 배포, 전송, 변형할 수 없습니다.
■ 본 리포트는 당사 리서치본부에서 수집한 자료 및 정보를 기초로 작성된 것이나 당사가 그 자료 및 정보의 정확성이나 완전성을 보장할 수는 없으므로 당사는 본 리포트로써 고객의 투자 결과에 대한 어떠한 보장도 행하는 것이 아닙니다. 최종적 투자 결정은 고객의 판단에 기초한 것이며 본 리포트는 투자 결과와 관련한 법적 분쟁에서 증거로 사용될 수 없습니다.
■ 본 리포트에 제시된 종목들은 리서치본부에서 수집한 자료 및 정보 또는 계량화된 모델을 기초로 작성된 것이나, 당사의 공식적인 의견과는 다를 수 있습니다.
■ 이 리포트에 게재된 내용들은 작성자의 의견을 정확하게 반영하고 있으며, 외부의 부당한 압력이나 간섭없이 작성되었음을 확인합니다.